

Ficha Técnica:

OPTIMIZACIÓN PARA CLOUD SCHEDULING MEDIANTE ENJAMBRE DE PARTÍCULAS (PSO)

Elaboró:

José Guadalupe Baños Monjaraz
04/mayo/2026

Monserrat Margarita Cruces Díaz

Información General

Nombre del Sistema	Institución
Sistema Metaheurístico de Optimización para Cloud Scheduling mediante Enjambre de Partículas (PSO)	Universidad Nacional Autónoma de México (UNAM) - Facultad de Ingeniería
Área Académica	Objetivo General
Inteligencia Artificial / Algoritmos Bioinspirados / Optimización Combinatoria	Implementar y calibrar el algoritmo PSO para resolver el problema de asignación de tareas en la nube, logrando la minimización efectiva del <i>Makespan</i> .

Descripción y Contexto

Sistema de optimización estocástica diseñado para distribuir inteligentemente cargas de trabajo heterogéneas dentro de un clúster de servidores simulado, utilizando principios de Inteligencia Colectiva (*Swarm Intelligence*).

Problema a Resolver

El *Cloud Scheduling* es un problema NP-duro. Asignar múltiples tareas a servidores con capacidades asimétricas genera cuellos de botella. El sistema evita la saturación individual de los nodos de cómputo.

Métrica de Evaluación

Makespan: El tiempo de finalización del recurso que más tarda en concluir su procesamiento. Matemáticamente: $M = \max(C_1, C_2, \dots, C_m)$. Minimizarlo garantiza eficiencia paralela.

Especificaciones Técnicas

Algoritmo Principal	Particle Swarm Optimization (PSO)
Naturaleza del Algoritmo	Metaheurística bioinspirada, estocástica, iterativa, poblacional.
Lenguaje Base	Python 3.x
Librerías / Dependencias	• NumPy: Vectorización matemática y álgebra lineal. • Matplotlib: Renderizado de curvas de convergencia. • CSV / JSON: Ingesta y serialización de datos estructurados.
Entradas (Inputs)	Archivos .csv con vectores de cargas de trabajo (ID de tarea, peso en millones de instrucciones y descripción).
Salidas (Outputs)	• Asignación de tareas óptima en formato .json. • Valor del <i>Makespan</i> mínimo (ms). • Gráficas 2D de convergencia.

Arquitectura y Funcionamiento



Representación de Datos

Mecánica Evolutiva

Codificación continua. La posición de cada partícula es un vector X que mapea las n tareas a m servidores mediante redondeo matemático.

Las partículas actualizan su velocidad y posición ponderando tres fuerzas:

1. **Inercia:** Trayectoria y momento previo.
2. **Factor Cognitivo:** Atracción hacia su mejor hallazgo histórico ($pBest$).
3. **Factor Social:** Atracción hacia el óptimo global del enjambre ($gBest$).

Flujo de Ejecución

1. Lectura CSV --> 2. Inicialización estocástica --> 3. Evaluación de fitness -->
--> 4. Actualización vectorial --> 5. Estabilización --> 6. Reporte JSON/Gráfico.

Resultados y métricas esperadas



Desempeño Observado

Convergencia acelerada y robusta frente a la aleatoriedad inicial.

Escenario de Prueba

- **Inicio:** *Makespan* deficiente en fase exploratoria (~170 ms).
- **Convergencia:** Caída drástica del error, estabilizándose alrededor de la iteración 8 (~165 ms).

- **Explotación:** La curva se mantiene plana el resto del ciclo, confirmando la solidez del óptimo local encontrado.

Ventajas Técnicas

Ejecución rápida sin la carga computacional de operadores evolutivos complejos (como el cruce en genéticos). Escala de manera estable al aumentar el volumen del CSV.

Proyección y Aplicabilidad



Aplicaciones Reales

- Enrutamiento de peticiones en clústeres Kubernetes.
- Balanceo de carga en servidores AWS / Google Cloud.
- Optimización térmica en Centros de Datos.
- Procesamiento distribuido en redes *Edge* e IoT.

Mejoras Futuras

Implementar paralelización (multiprocessing) y adaptación a entornos de demanda en tiempo real.

Documentos de Referencia

- NTC ISO 9000:2005 Sistema de Gestión de la Calidad. Fundamentos y Vocabulario.
- NTC ISO 9001:2008 Sistema de Gestión de la Calidad. Requisitos.
- NTC GP 1000:2009 Norma Técnica de Calidad en la Gestión Pública.